

Reference-Relative Generative Information Design

问题、算法、核心理论与首阶段实验计划

研究规格草案（中文，面向 ICLR 方法型论文）

2026 年 8 月

摘要

本文整理当前冻结版本的 Reference-Relative Generative Information Design (RR-GID)。已有完整 reference population，并训练得到冻结的高维生成器 G_0 ；新的 target population 每个独立 unit 只能测量一个受限 panel。目标不是补全单个样本，而是在固定 measurement budget 下恢复 target 的完整联合分布。我们用 reference-relative exponential tilt 建模 target shift，利用 reference generator 的完整条件结构计算 panel 对 relative-score directions 的 Fisher information，并由 full-target KL 风险导出最优 allocation。算法仅包含 balanced pilot、一次 generator-aware design、主数据采集和少量 Fisher-scoring 更新。本文给出当前主理论包的严格陈述，并将首阶段实验压缩为一个可解析的 nonlinear synthetic benchmark 与一个 Gas Sensor Drift 真实数据集，重点验证 statistical optimality、nonlinear conditional information 与 generator reuse。

一句话：reference generator 不负责把 target 缺失坐标当成真值补全；它提供 $Q_0(X_{S^c} | X_S)$ 这一可复用 conditional-law interface，用来评估“测这个 panel 能对完整 target shift 提供多少信息”，从而把有限 target budget 花在最有价值的测量上。

1 背景与 Motivation

现实中常见如下结构：历史/reference 总体已有完整高维数据，因此可以训练较强的生成模型；但后续 target 总体的完整测量昂贵、耗时或有受访负担，每个新 unit 只能测量少量变量。例如多传感器系统中只能激活少量传感器，或 split questionnaire 中每个受访者只回答一部分问题。

直接用 reference generator 对 target 未测变量做 imputation 并不能解决根本问题：即使 Q_0 已知，如果 target 可以沿任意不可观测方向变化，合法 panels 的 marginals 也可能完全相同而完整 target law 不同。因此必须限制 reference 到 target 的相对变化；同时，测量设计应针对这些允许的 shift directions，而不是只追求变量覆盖或 pairwise correlation。

本文采用低维 relative tilt，但允许 Q_0 本身保持复杂 multimodality、高阶依赖和非线性 conditional structure。与 classical split-questionnaire OED 相比，关键变化在于：panel value 不再由 Gaussian covariance 决定，而由完整 relative score 在 $\sigma(X_S)$ 上的条件投影决定；与一般 active feature acquisition 不同，本问题是 **population-level prospective allocation**，panel 在当前 unit 到来前决定，最终目标是 full target law 而非单个 downstream prediction。

2 Formal Formulation

完整变量

$$X = (X_1, \dots, X_d) \in \mathcal{X}.$$

冻结 reference generator G_0 诱导分布 Q_0 。理论不要求解析 density，只要求可从 Q_0 full sampling，并可近似从任意合法 panel 的 conditional law $Q_0(X_{S^c} | X_S = x_S)$ 采样。

在 target campaign 开始前固定 feature map

$$\phi: \mathcal{X} \rightarrow \mathbb{R}^r,$$

并定义 relative exponential family

$$\frac{dQ_\beta}{dQ_0}(x) = \exp\{\beta^\top \phi(x) - A(\beta)\}, \quad A(\beta) = \log \mathbb{E}_{Q_0} e^{\beta^\top \phi(X)}. \quad (1)$$

主理论假设真实 target 为 $Q^* = Q_{\beta^*}$ 。 ϕ 限制的是 reference $\rightarrow$ target 的变化，而不是 Q_0 的复杂度。

合法 panel family 为 $\mathcal{S}$ 。第 i 个 target unit 到来前, 根据历史选择 $S_i \in \mathcal{S}$, 随后只观察 X_{i,S_i} ; 满足 prospective 条件 $X_i \perp S_i \mid H_{i-1}$ 。总成本 $\sum_i c(S_i) \leq B$ 。最终输出 $Q_{\hat{\beta}_B}$, 目标最小化

$$\mathbb{E} \text{KL}(Q_{\beta^*} \| Q_{\hat{\beta}_B}).$$

第一版理论采用: 有限 $\mathcal{S}$, $0 < c_{\min} \leq c(S) \leq c_{\max}$; β^* 位于紧致参数集内部; ϕ 有界(之后可放宽为局部 exponential moment); exponential family minimal; 并存在某 allocation 使所有 shift directions collectively observable。

3 Generator-Aware Information Geometry

完整 score 与 full Fisher information 为

$$s_\beta(X) = \phi(X) - \mu_\beta, \quad \mu_\beta = \mathbb{E}_\beta \phi(X), \quad F(\beta) = \text{Var}_\beta(\phi(X)). \quad (2)$$

只观察 X_S 时, panel marginal score 恰为

$$m_{\beta,S}(x_S) = \mathbb{E}_\beta[s_\beta(X) \mid X_S = x_S], \quad (3)$$

其 Fisher information 为

$$I_S(\beta) = \text{Var}_\beta\{m_{\beta,S}(X_S)\}. \quad (4)$$

若 p_S 表示总测量成本中分给 panel S 的比例, 则单位成本 information

$$M_\beta(p) = \sum_{S \in \mathcal{S}} \frac{p_S}{c(S)} I_S(\beta), \quad p \in \Delta_{\mathcal{S}}. \quad (5)$$

为什么不是 covariance。 对任意方向 v , 令 $Y_v = v^\top s_\beta(X)$ 。有变分表征

$$v^\top I_S v = \sup_{g \in L_2(X_S)} \{2\mathbb{E}[g(X_S)Y_v] - \mathbb{E}[g(X_S)^2]\}. \quad (6)$$

对任意受限 predictor class $\mathcal{G}_S$, restricted information 与 full information 的精确 gap 为

$$v^\top I_S v - \mathcal{I}_{S,\mathcal{G}}(v) = \inf_{g \in \mathcal{G}_S} \mathbb{E}[g(X_S) - \mathbb{E}(Y_v \mid X_S)]^2. \quad (7)$$

因此 linear/covariance design 只是取 $\mathcal{G}_S$ 为线性函数的特例; 完整 conditional law 对应 unrestricted endpoint。

4 算法: Formal Pilot-Design-Update RR-GID

本节给出与理论对象一一对应的 formal algorithm。设 $A_a \subseteq [d]$ 为 feature ϕ_a 的最小坐标 support。除 G_0 的 full/conditional sampling 外, 算法使用两个由 reference generator 诱导的 tilted sampling primitives:

$$\text{TiltFull}(\beta): X \sim Q_\beta, \quad \text{TiltCond}(\beta, S, x_S): X_{S^c} \sim Q_\beta(\cdot \mid X_S = x_S).$$

它们可由 Q_0 full/conditional proposals 加权或 accept-reject 得到; 理论将其视为 exact oracle, 有限 Monte Carlo 误差在 supporting theory 中单独处理。对实际 target observation $y = x_S$, 记

$$m_{\beta,S}(y) = \mathbb{E}_\beta[s_\beta(X) \mid X_S = y], \quad s_\beta(X) = \phi(X) - \mu_\beta.$$

4.1 Monte Carlo 子程序与预算离散化

Reference log-partition approximation。 先固定一个独立 reference pool $\{X_0^{(r)}\}_{r=1}^{R_A} \stackrel{\text{iid}}{\sim} Q_0$, 定义

$$\hat{A}_{R_A}(\beta) = \log \left\{ \frac{1}{R_A} \sum_{r=1}^{R_A} \exp(\beta^\top \phi(X_0^{(r)})) \right\}. \quad (8)$$

在 oracle synthetic 中可用解析/高精度 A ; 在 learned-generator 实验中统一使用 Equation (8)。

Panel information estimator. 给定参数 β , 先采 N_g 个 full tilted samples $Z_n \sim Q_\beta$, 记

$$\hat{\mu}_\beta = \frac{1}{N_g} \sum_{n=1}^{N_g} \phi(Z_n), \quad \hat{F}_\beta = \frac{1}{N_g - 1} \sum_{n=1}^{N_g} (\phi(Z_n) - \hat{\mu}_\beta)(\phi(Z_n) - \hat{\mu}_\beta)^\top.$$

对每个 $S \in \mathcal{S}$, 令 $Y_{S,n} = (Z_n)_S$. 条件于同一 $Y_{S,n}$, 独立生成两批

$$X_{S,n,\ell}^{(a)} \sim Q_\beta(\cdot \mid X_S = Y_{S,n}), \quad a \in \{1, 2\}, \ell = 1, \dots, L_I,$$

并定义

$$\bar{s}_{S,n}^{(a)} = \frac{1}{L_I} \sum_{\ell=1}^{L_I} \{\phi(X_{S,n,\ell}^{(a)}) - \hat{\mu}_\beta\}.$$

令 $\bar{s}_S^{(a)} = N_g^{-1} \sum_n \bar{s}_{S,n}^{(a)}$, 则使用对称 cross-covariance

$$\tilde{I}_S(\beta) = \frac{1}{2(N_g - 1)} \sum_{n=1}^{N_g} \left[(\bar{s}_{S,n}^{(1)} - \bar{s}_S^{(1)})(\bar{s}_{S,n}^{(2)} - \bar{s}_S^{(2)})^\top + (1 \leftrightarrow 2) \right]. \quad (9)$$

理论上 $\mathbb{E}\tilde{I}_S = I_S$. 数值优化时可令 $\hat{I}_S = \Pi_{\mathcal{S}_+^*}(\tilde{I}_S)$; 该 PSD projection 仅用于 finite-sample stability.

Cost-share rounding. 设计变量 p_S 表示**总成本份额**而非 unit-level sampling probability. 给定可用预算 B' , 实现时取

$$n_S(B', p) = \left\lfloor \frac{B' p_S}{c(S)} \right\rfloor, \quad (10)$$

剩余不足一个 panel 的预算可忽略, 或按 fractional remainder 从大到小补齐; 无论哪种实现均满足 $n_S c(S)/B' = p_S + O(B'^{-1})$.

4.2 Cost-aware design solver

给定 $\hat{F} \succ 0$ 与 $\{\hat{I}_S\}$, 定义

$$\widehat{M}(p) = \sum_{S \in \mathcal{S}} \frac{p_S}{c(S)} \hat{I}_S, \quad \widehat{\Phi}(p) = \text{tr}\{\hat{F} \widehat{M}(p)^{-1}\}.$$

选择一个已知可观测的 safe allocation p^{safe} 使 $\widehat{M}(p^{\text{safe}}) \succ 0$. Frank-Wolfe 的 sensitivity 为

$$\gamma_S(p) = \frac{1}{c(S)} \text{tr}\{\widehat{M}(p)^{-1} \hat{F} \widehat{M}(p)^{-1} \hat{I}_S\}, \quad (11)$$

并有 certificate $g_{\text{FW}}(p) = \max_S \gamma_S(p) - \widehat{\Phi}(p)$.

Input: $\hat{F}$; $\{\hat{I}_S, c(S)\}_{S \in \mathcal{S}}$; safe allocation p^{safe} ; tolerance $\tau_{\text{FW}} > 0$

Output: $\hat{p}$ and certificate $g_{\text{FW}}(\hat{p})$

$p^{(0)} \leftarrow p^{\text{safe}}; t \leftarrow 0$

repeat

$M_t \leftarrow \sum_S p_S^{(t)} \hat{I}_S / c(S); \Phi_t \leftarrow \text{tr}(\hat{F} M_t^{-1})$
 $\gamma_S^{(t)} \leftarrow c(S)^{-1} \text{tr}(M_t^{-1} \hat{F} M_t^{-1} \hat{I}_S)$ for every $S \in \mathcal{S}$
 $S_t \leftarrow \arg \max_{S \in \mathcal{S}} \gamma_S^{(t)}; g_t \leftarrow \gamma_{S_t}^{(t)} - \Phi_t$
if $g_t > \tau_{\text{FW}}$ **then**
 $\eta_t \leftarrow \arg \min_{\eta \in [0,1]} \widehat{\Phi}((1-\eta)p^{(t)} + \eta e_{S_t})$
 $p^{(t+1)} \leftarrow (1-\eta_t)p^{(t)} + \eta_t e_{S_t}; t \leftarrow t+1$
end

until $g_t \leq \tau_{\text{FW}}$

return $\hat{p} \leftarrow p^{(t)}, g_{\text{FW}}(\hat{p}) \leftarrow g_t$

Algorithm 1: Cost-aware Frank-Wolfe design solver

4.3 完整 RR-GID 伪代码

Pilot 采用 deterministic balanced counts, 而不是把 cost share 误当成 unit-level probability. 给定 pilot safe allocation p^{bal} , 先用 Equation (10) 得到 $n_S^0 = n_S(b, p^{\text{bal}})$, 令 $n_0 = \sum_S n_S^0$, 并对 feature a 定义实际 pilot coverage frequency

$$\rho_a = \frac{1}{n_0} \sum_{S \in \mathcal{S}} n_S^0 \mathbf{1}\{A_a \subseteq S\} > 0. \quad (12)$$

因此下述 HT moment estimator 在 prospective sampling 下严格无偏。

Input: reference generator G_0 ; feature map $\phi = (\phi_1, \dots, \phi_r)$ and supports $\{A_a\}$; parameter set Θ ; panels $\mathcal{S}$ and costs c ; total budget B ; pilot budget b ; balanced/safe allocation p^{bal} ; MC sizes (R_A, N_g, L_I, L_U) ; scoring steps J ; FW tolerance τ_{FW}

Output: design $\hat{p}$; integer panel counts $\{n_S^0 + n_S^1\}$; estimator $\hat{\beta}_B$; target generator $Q_{\hat{\beta}_B}$

1. **Reference preparation.** Draw $\{X_0^{(r)}\}_{r=1}^{R_A} \sim Q_0$ once and construct $\hat{A}_{R_A}(\beta)$ by Equation (8).

2. **Balanced pilot.** Set $n_S^0 \leftarrow \lfloor bp_S^{\text{bal}}/c(S) \rfloor$ and collect n_S^0 independent target units under each S . Let $\mathcal{D}_0 = \{(S_i, Y_i)\}_{i=1}^{n_0}$, $Y_i = X_{i, S_i}$. Compute ρ_a by Equation (12) and

$$\hat{\mu}_a^{\text{pil}} \leftarrow \frac{1}{n_0} \sum_{i=1}^{n_0} \frac{\mathbf{1}\{A_a \subseteq S_i\}}{\rho_a} \phi_a(X_i), \quad a = 1, \dots, r,$$

where $\phi_a(X_i)$ is evaluated only when $A_a \subseteq S_i$.

$\tilde{\beta} \leftarrow \arg \min_{\beta \in \Theta} \{\hat{A}_{R_A}(\beta) - \beta^\top \hat{\mu}^{\text{pil}}\}$.

3. **Generator-aware information at $\tilde{\beta}$.** Using TiltFull and TiltCond, compute $\hat{F}(\tilde{\beta})$ and $\{\hat{I}_S(\tilde{\beta})\}_{S \in \mathcal{S}}$ by Equation (9).

4. **Design once.** Run the preceding Frank–Wolfe solver with $p^{\text{safe}} = p^{\text{bal}}$ and obtain $\hat{p}$ satisfying $g_{\text{FW}}(\hat{p}) \leq \tau_{\text{FW}}$.

5. **Main campaign.** Set $B_1 \leftarrow B - \sum_S n_S^0 c(S)$ and $n_S^1 \leftarrow \lfloor B_1 \hat{p}_S / c(S) \rfloor$. Collect n_S^1 new independent target units for each S ; let $\mathcal{D}_1$ denote these observations and $\mathcal{D}_B \leftarrow \mathcal{D}_0 \cup \mathcal{D}_1$.

6. **J -step relative-shift update.** Set $\beta^{(0)} \leftarrow \tilde{\beta}$.

for $j = 0, \dots, J-1$ do

Using TiltFull($\beta^{(j)}$), estimate $\hat{\mu}_j \approx \mu_{\beta^{(j)}}$. For every active panel S , re-estimate $\hat{I}_{j,S} \approx I_S(\beta^{(j)})$ by cross-completion.

For each $(S_i, Y_i) \in \mathcal{D}_B$, draw L_U independent completions $X_{i,\ell}^{(j)} \sim Q_{\beta^{(j)}}(\cdot \mid X_{S_i} = Y_i)$ and set

$$\hat{m}_i^{(j)} \leftarrow \frac{1}{L_U} \sum_{\ell=1}^{L_U} \phi(X_{i,\ell}^{(j)}) - \hat{\mu}_j.$$

$\hat{U}_j \leftarrow \sum_{(S_i, Y_i) \in \mathcal{D}_B} \hat{m}_i^{(j)}$; $\hat{H}_j \leftarrow \sum_{S \in \mathcal{S}} (n_S^0 + n_S^1) \hat{I}_{j,S}$.

$\beta^{(j+1)} \leftarrow \Pi_\Theta \{\beta^{(j)} + \hat{H}_j^{-1} \hat{U}_j\}$.

end

7. **Return.** $\hat{\beta}_B \leftarrow \beta^{(J)}$ and $dQ_{\hat{\beta}_B}/dQ_0 \propto \exp\{\hat{\beta}_B^\top \phi(X)\}$.

Algorithm 2: Formal Pilot–Design–Update RR-GID

与理论版本的对应。主 T3/T4 使用 exact observed score, 或令 update-stage $L_U = L_{U,B} \rightarrow \infty$, 且 generator information estimation error 为 $o_p(1)$ 。固定 L_U 时, 算法仍一致地实现一个 simulated estimating equation, 但最终 asymptotic covariance 变为 sandwich

$$M(p)^{-1} V_{L_U}(p) M(p)^{-1}, \quad V_{L_U}(p) = \sum_S \frac{p_S}{c(S)} [I_S + L_U^{-1}(F - I_S)].$$

Design-stage 的 cross-completion 则对任意固定 $L_I \geq 1$ 都消除了 I_S 的 Monte Carlo upward bias。

5 核心理论结果

以下仅列主文应强调的结果。support-size、basis invariance、Frank–Wolfe certificate、learned-generator perturbation 等均作为 supporting propositions。

5.1 识别边界与 conditional information

若 observable space

$$\mathcal{O} = \text{span}\{g(X_S) : S \in \mathcal{S}, g \in L_2(Q_{0,S})\}$$

存在非零有界 $h \in L_2^0(Q_0) \cap \mathcal{O}^\perp$, 则 $dQ_\pm/dQ_0 = 1 \pm \epsilon h$ 在所有合法 panel 上有相同 marginals, 但 $Q_+ \neq Q_-$ 。因此 reference 本身不能识别 arbitrary target shift。

在 relative family 内, $M_\beta(p) \succ 0$ 当且仅当不存在 $v \neq 0$ 使 $\mathbb{E}_\beta[v^\top s_\beta(X) \mid X_S] = 0$ 对所有 active panels 成立; Equation (6)–(7)进一步刻画不同 predictor classes 丢失多少 information。

5.2 Full-KL local asymptotic minimax optimality

对 cost-normalized panel counts 收敛到 p , partial-panel experiment 在 local alternative $\beta^* + h/\sqrt{B}$ 下满足 LAN, 极限 information 为 $M_{\beta^*}(p)$ 。由于

$$\text{KL}(Q_\beta \| Q_{\beta+u}) = \frac{1}{2} u^\top F(\beta) u + O(\|u\|^3),$$

正确的 Hájek–Le Cam local asymptotic minimax constant 为

$$\boxed{\frac{1}{2} \text{tr}(F(\beta^*) M_{\beta^*}(p)^{-1})}. \quad (13)$$

对 regular efficient estimator, 在二阶矩一致可积条件下,

$$\mathbb{E} \text{KL}(Q_{\beta^*} \| Q_{\hat{\beta}_B}) = \frac{1}{2B} \text{tr}(F M^{-1}) + o(B^{-1}).$$

故 oracle design 正是

$$p^* \in \arg \min_p \Phi_{\beta^*}(p), \quad \Phi_{\beta}(p) = \text{tr}(F(\beta) M_{\beta}(p)^{-1}). \quad (14)$$

5.3 一次设计即可达到 oracle first-order efficiency

令 pilot budget $b_B = B^\gamma$ (实践中可乘固定常数), $0 < \gamma < 1$ 。若 $\tilde{\beta} - \beta^* = O_p(B^{-\gamma/2})$, generator information estimates 与 design optimization 一致, 则

$$\Phi_{\beta^*}(\tilde{p}) \rightarrow_p \min_p \Phi_{\beta^*}(p).$$

从 $\tilde{\beta}$ 做 J 次 Fisher scoring 有

$$\|\beta^{(J)} - \beta^*\| = O_p(B^{-1/2} + B^{-2^J \gamma/2}). \quad (15)$$

因此只要 $2^J \gamma > 1$, 最终达到 Equation (13) 的 oracle first-order constant。例如 $\gamma = 1/3$ 时两次 scoring 足够。

5.4 为什么 full conditional structure 值得学习

对任意 fixed order q 与任意 K , 可构造 K 个 full-support reference worlds, 使它们所有至多 q 个坐标的 marginals 完全相同, 但 optimal panel 分别是 K 个不同 panels。任何只依赖这些 bounded-order marginals 的 design rule 必须在所有 worlds 输出同一 allocation, 因此至少有一个 world 满足

$$\frac{\Phi(p_{\text{bounded-order}})}{\Phi(p^*)} \geq K. \quad (16)$$

由于 K 任意, fixed-order summaries 没有有限的 uniform approximation ratio。

另一方面, 在 $\beta = 0$ 时

$$m_{0,S}^h(x_S) = \mathbb{E}_0[h(X) \mid X_S = x_S] - \mathbb{E}_0 h(X).$$

若一个 oracle 能对 measure-determining function class 中所有 post-hoc h 回答上述 conditional-score query, 则这些 conditional expectations 唯一确定 $Q_0(X_{S^c} \mid X_S)$; 反方向显然。因此 universal conditional-score access 与 conditional-law access 在信息意义上等价。这解释了为什么 frozen conditional generator 是跨 ϕ 、panel 与 target campaign 复用的自然接口, 但并不声称单个固定任务上 generator 必然优于强 discriminative regressor。

6 首阶段实验: 目标与统一比较方法

首阶段只做一个 synthetic 主环境和一个真实数据集。所有主结果统一比较四种 acquisition policies:

方法	身份	实现/作用
Uniform SQD	literature-standard	在所有候选 panels 上均匀随机, 作为无模型基线。
A-OSQD	published baseline	按 Jang et al. 的 multivariate-normal mean A-optimal split questionnaire design, 用完整 reference covariance 计算 panel Fisher information, 优化 $\text{tr}(M_A^{-1})$ 。
Discriminative Score OED	我们的强 ablation	用同一完整 reference data、当前 $\tilde{\beta}$ 训练 mask-conditioned network, 直接回归 $m_{\tilde{\beta}, S}(X_S)$, 再按 $\text{tr}(FM^{-1})$ 设计。
RR-GID	ours	frozen arbitrary-conditioning generator 提供 conditional samples, 估计完整 nonlinear I_S 后做 full-KL design。

表 1: 第一阶段只保留四种 acquisition policies。主比较中四种方法收集数据后使用同一 final RR estimator, 以隔离 allocation 本身的贡献。

Generator 实现。 第一阶段固定使用 VAEAC (Variational Autoencoder with Arbitrary Conditioning) 作为 G_0 : 它原生支持给定任意 observed subset 后一次性采样 missing subset。本文的理论和方法不绑定 VAEAC; 它只是首个可执行 backbone。对 tilt Q_β , 因为所有 ϕ_a 取 bounded transform, 可用 Q_0 full/conditional samples 做 accept-reject; 同时记录 unconditional/conditional acceptance rate 与 importance ESS, 低 overlap 的 run 单独标记。

Discriminative Score OED。 对当前 campaign 的 $\tilde{\beta}$, 在完整 reference samples 上构造 label $s_{\tilde{\beta}}(X)$; 使用权重 $w(X) \propto e^{\tilde{\beta}^\top \phi(X)}$, 训练一个输入为 “masked X + mask” 的 MLP 输出 r 维 score。mask 从候选 panel library 均匀抽取。用独立 reference validation set 估计各 panel 的 $\hat{I}_S = \text{Cov}_w\{g(X_S)\}$ 。每个新 campaign 重新训练; 这是一条刻意设置得较强的 fixed-task 非生成式替代方案。

7 Synthetic: Nonlinear Conditional-Information Benchmark

7.1 数据生成与 ground-truth oracle

固定 $d = 16$ 。先生成四成分 latent Gaussian mixture

$$Z \sim \sum_{m=1}^4 \pi_m \mathcal{N}(\mu_m, \Sigma_m), \quad \pi_m = 1/4,$$

其中 mixture 参数只在实验开始时用 seed 2026 生成一次并冻结: $\mu_m \sim \mathcal{N}(0, 1.5^2 I)$; $\Sigma_m = D_m + L_m L_m^\top$, $L_m \in \mathbb{R}^{16 \times 4}$ 元素服从 $\mathcal{N}(0, 0.25^2)$, D_m 对角元素均匀取 $[0.4, 0.8]$ 。然后逐坐标做可逆 warp

$$X_j = T_\alpha(Z_j) = \begin{cases} \sinh(\alpha Z_j)/\alpha, & \alpha > 0, \\ Z_j, & \alpha = 0. \end{cases}$$

因为 T_α 可逆, 给定任意 X_S 可以还原 Z_S , 利用 Gaussian-mixture conditioning 得到**精确 conditional oracle**; 因此可高精度计算 oracle I_S 与 p^* 。

用 Q_0 大样本得到每个坐标的 reference scale, 记标准化值为 $\tilde{X}_j$ 。固定 $r = 12$:

$$\phi_j = \tanh(\tilde{X}_j), \quad j = 1, \dots, 6; \quad \phi_{6+j} = \tanh(\tilde{X}_j \tilde{X}_{j+6}), \quad j = 1, \dots, 6.$$

候选 panels 为全部坐标 pairs, $|S| = \binom{16}{2} = 120$, 成本相同。balanced pilot 只在 6 个直接 pair supports 与少量覆盖 unary features 的 pairs 上均匀分配。 β^* 的方向随机后冻结, 每个 replication 只改变 target samples; 其 scale 用独立 Q_0 pool 二分调整, 使 global importance ESS/N 约为 0.5, 避免实验退化为 overlap failure。

7.2 S1: 正文主实验——statistical optimality

主 nonlinear strength 设 $\alpha = 1$ 。reference train/validation 各使用 50,000/10,000 个完整 samples; VAEAC 只训练一次。target budgets

$$B \in \{2000, 4000, 8000, 16000, 32000\}, \quad b_B = \lceil 10B^{1/3} \rceil, \quad J = 2.$$

对每种 policy 分配主 campaign panels; 为了**纯验证 T3/T4**, 这一张主图的 final observed score 使用 exact conditional oracle, 因此四种方法的区别只有 allocation。每个 B 运行至少 200 个独立 target replications。

Primary metric 是 exact

$$B \cdot \text{KL}(Q_{\beta^*} \| Q_{\hat{\beta}}),$$

并画 oracle horizontal line $\frac{1}{2} \min_p \Phi_{\beta^*}(p)$ 。同时报告 design ratio

$$\Phi_{\beta^*}(\hat{p}) / \Phi_{\beta^*}(p^*).$$

在一个固定 budget (建议 $B = 8000$) 做极小 ablation: $J \in \{0, 1, 2\}$; 理论预期 $\gamma = 1/3$ 时 $J = 2$ 首次满足 $2^J \gamma > 1$ 。

7.3 S2: 机制分析——nonlinearity 与 generator reuse

Nonlinearity sweep: 固定 $B = 8000$, 令 $\alpha \in \{0, 0.5, 1.0, 1.5\}$ 。报告四种方法的 design ratio, 以及 $\max_S \|\hat{I}_S - I_S\|_{\text{op}}$ 。预期 A-OSQD/linear Gaussian information 在 α 增大时逐步偏离 oracle; Discriminative Score OED 与 RR-GID 应能继续利用 nonlinear conditional information。

Reuse: reference generator 只训练一次; 随后创建 $T \in \{1, 5, 20, 50\}$ 个新 campaigns, 每个 campaign 在预先定义的 bounded unary/pairwise feature dictionary 中重新抽取 12 个 ϕ , 并重新抽取 β^* 与一部分 candidate pair panels。RR-GID 不重训 G_0 ; Discriminative Score OED 每个 campaign 重新拟合 score network。主图只画“累计训练 + 推断 compute vs. 平均 design regret”。不要预设 generator 必须在单任务更准; 目标是检验其是否具有更好的跨 campaign amortized frontier。

8 Real Data: Gas Sensor Array Drift

UCI Gas Sensor Array Drift at Different Concentrations 含 13,910 次测量、16 个 chemical sensors、6 种气体; 每个 sensor 提取 8 个动态/稳态特征, 共 128 维, 并按时间组织为 10 个 batches, 覆盖约 36 个月。该结构非常适合“每个 unit 只能启用少量 sensors”的 prospective panel design。

8.1 预处理、reference/target 与 panel 定义

使用 batches 1–6 作为 reference; 随机分 80%/20% 为 generator train/validation。自然 target 定义为三次后续 campaigns: batch 7、batches 8–9、batch 10。每个 target campaign 再固定划分一半为 **campaign pool** (算法只能从中获得被 panel masking 后的数据), 另一半为 **full-test pool** (只用于 evaluation); 为允许统一预算, 每次 replication 从 campaign pool 有放回抽取独立 units。

每个 sensor 的 8 个特征组成一个 measurement module; 候选 panel 是任意两个 sensors, 因此 $|\mathcal{S}| = \binom{16}{2} = 120$ 且成本完全相同。所有 128 个 raw features 用 reference train 的 mean/std 标准化。对每个 sensor block 在 reference train 上单独做 PCA, 取 PC1 得到标量 z_j , 再固定

$$\phi_j = \tanh(z_j), \quad j = 1, \dots, 8; \quad \phi_{8+j} = \tanh(z_j z_{j+8}), \quad j = 1, \dots, 8.$$

因此 $r = 16$, 所有 feature supports 都被 pairs $(j, j+8)$ 直接覆盖; balanced pilot 就在这 8 个 pairs 上均匀抽样。VAEAC 输入/输出仍是完整 128 维标准化 sensor features, PC1 只用于构造 relative-shift features。

8.2 R1: 先做 well-specified 半合成验证

先在真实 reference joint structure 上做一个干净的半合成 target: 从 reference validation 完整 records 构造 empirical base distribution, 按

$$w_i(\beta^*) \propto e^{\beta^{*\top} \phi(x_i)}$$

重采样 target; β^* scale 同样调到 ESS/N ≈ 0.5 。这样 ground-truth target 保留真实 sensor dependence, 同时 full-law KL (相对 empirical base) 可精确/高精度计算。使用

$$B \in \{400, 800, 1600, 3200\}, \quad b_B = \min\{0.2B, \lceil 10B^{1/3} \rceil\}, \quad J = 2.$$

主比较仍是四种 acquisition policies; 这一部分首先确认 learned generator 估计出的 panel ranking 能否在真实高维 dependence 下接近 oracle。

8.3 R2: 自然时间漂移

对三个 natural target campaigns 重复相同 budget sweep。由于真实 drift 未必满足 exponential tilt, 主文不把它当成 T3/T4 的 exact verification, 而作为 robustness test。

对每个 target full-test pool, 先计算当前冻结 reference generator family 内的 oracle projection: 用完整 target 估计 $\mu_t = \mathbb{E}_{P_t} \phi(X)$, 再解

$$\beta_t^\dagger = \arg \min_{\beta} \{\hat{A}(\beta) - \beta^\top \hat{\mu}_t\},$$

其中 $\hat{A}(\beta) = \log \mathbb{E}_{\hat{Q}_0} e^{\beta^\top \phi(X)}$ 用一个固定的大规模 VAEAC full-sample pool 估计。这个 $\beta_t^\dagger$ 仅用于 evaluation, 绝不提供给 acquisition algorithm。

Primary metric 是 family 内 estimation loss

$$D_{\hat{A}}(\hat{\beta}, \beta_t^\dagger) = \hat{A}(\hat{\beta}) - \hat{A}(\beta_t^\dagger) - (\hat{\beta} - \beta_t^\dagger)^\top \nabla \hat{A}(\beta_t^\dagger), \quad (17)$$

即 $\hat{Q}_{\beta_t^\dagger}$ 与 $\hat{Q}_{\hat{\beta}}$ 的 KL/Bregman distance。再报告两个 model-independent secondary metrics:

1. **Held-out moment RMSE:** 在 reference 阶段冻结 32 个不属于 ϕ 的 test functions (16 个各 sensor 的 PC2 bounded unary + 16 个预先固定的跨 sensor interactions), 比较生成的 $\hat{Q}_{\hat{\beta}}$ 与 full-test target 的 moments;
2. **C2ST AUC:** 从 $\hat{Q}_{\hat{\beta}}$ 采样与 full-test target 等量数据, 用固定 5-fold classifier two-sample test; AUC 越接近 0.5 越好。

每个 target campaign/budget 至少做 50 次 paired replications; 四种 methods 使用相同 target draws。另报告 overlap ESS、conditional acceptance rate、FW gap 与 $\lambda_{\min}(\hat{M})$ 作为失败诊断。

9 实现顺序与第一阶段交付物

为避免同时调试过多模块, 建议严格按以下顺序执行:

1. **Synthetic oracle pipeline:** 实现 GMM+warp、exact conditional sampler、 I_S 、Frank-Wolfe、pilot 和 scoring; 先只跑 Uniform/A-OSQD/oracle RR-GID, 确认 $B \cdot KL$ 向理论常数收敛。
2. **加入 Discriminative Score OED:** weighted mask-conditioned MLP; 用 true I_S 检查 panel ranking 和 design regret。
3. **加入 VAEAC:** 先验证 arbitrary-pair conditional reconstruction; 再实现 tilt accept-reject、cross-completion I_S 和 RR-GIDallocation; 完成 nonlinearity/reuse 两个 mechanism plots。
4. **Gas Sensor:** 固定 preprocessing、PC features、120 pair panels; 先跑 R1 半合成, 只有当 R1 能稳定复现 synthetic 的 panel-ranking 现象后, 再跑 R2 natural drift。

第一阶段主文只需要四张图和一张表: **Fig.1** synthetic $B \cdot KL + J$ ablation; **Fig.2** nonlinearity 与 reuse; **Fig.3** Gas Sensor R1/R2 budget curves; **Fig.4** real-data information fidelity / cumulative compute; **Table 1** 三个 natural campaigns 的 projection loss、held-out moment RMSE 与 C2ST。若这套结果已经支持核心 story, 再决定是否补 parity visualization、KL-SQD、第二 generator backbone 或第二 real dataset。

参考文献

- [1] D.-G. Jang, Z. Zhu, and C. Yu. A-Optimal Split Questionnaire Designs for Multivariate Continuous Variables. *arXiv:2203.04883*, 2022.
- [2] O. Ivanov, M. Figurnov, and D. Vetrov. Variational Autoencoder with Arbitrary Conditioning. *International Conference on Learning Representations (ICLR)*, 2019.
- [3] A. Vergara et al. Gas Sensor Array Drift at Different Concentrations. UCI Machine Learning Repository, 2013. Dataset DOI: 10.24432/C5MK6M.
- [4] L. Le Cam and G. L. Yang. *Asymptotics in Statistics: Some Basic Concepts*. Springer, 2nd edition, 2000.
- [5] A. W. van der Vaart. *Asymptotic Statistics*. Cambridge University Press, 1998.