

P4 停在 G3：实现、诊断结果与后续算力

Phase 0–2 与 G0–G3 全部过门；G4 已停，不进入 plugin 设计

2026年9月2日

G4 plugin 已于 2026-09-02 11:36 (CST) 从开发机杀掉。GPU 空闲。本文件只依据已经写出证书的 Phase 0–2 与 G0–G3。所有阶梯运行都标了 `not_formal: true`，**不能当论文里的 50 次正式 replication**。

一句话： 同一 (Q_0) 下的评估链条、oracle 分配、估计 H、有限 score (QMC 与 LU=415 rejection) 都过了工程灾难门。正式 P4 要验的是「oracle 分配下估计器是否一阶有效」，G3 已经覆盖这条链；G4 是另一件事（用 $\widehat{p}(\widetilde{\beta})$ 代替 p^* ）。按当前数字，**oracle RR-GID 在 (J=4) 上大概率能合格**；若正式配置仍用 (J=2)，合格不再是「几乎肯定」。算力上：继续用拒绝抽样大约 **一到三个月**；先做性能重构再走 QMC，正式 sweep 大约 **三到十天**。

机器：开发机单卡 RTX 4080 SUPER 32GB。Gold 基线： `results/p4/phase2_gold_full16_20260827`。理论常数 $(\varphi/2 = 33.6078)$ 。Pilot: $(\lceil 10 B^{1/3} \rceil)$ 。种子： `202600000 + budget*1000 + replication`。正式 replication 一律 50，禁止 200。

0. 这次停了什么，证书停在哪

项目	状态
Phase 0–2	通过，证书已写
G0、G1 带帽、G2、G3 QMC、G3 rejection	全部 <code>ladder_passed: true</code>
G1 无帽	故意保留的失败对照，不算通过
G4 plugin	已停 。远程目录 <code>/root/autodl-tmp/rr_g4/g4_20260831</code> 里有 replication 0 的三行日志， 不下载、不验收、不引用为结果
正式 3 政策 × 5 预算 × 50 次	未开
Phase 4 性能重构、Phase 5 pilot 比较	未开

G4 杀掉前 replication 0 已经跑完 (J=0/2/4) (设计比 1.08，终端风险比 1.49，约 7 分钟)。这只说明进程是活的，**一张 replication 不能当 plugin 门**。后面正文不再使用这些数字。

1. 先分清：阶梯诊断 ≠ 正式实验

审查指南把 P4 拆成两扇门。当前规划里的正式 P4 是第一扇：

Oracle-allocation estimator gate。三个政策是 Uniform SQD、A-OSQD、oracle RR-GID。其中 oracle RR-GID **直接使用**在 (β^*) 处预先求好的 (p^*) ，不是用 pilot 上估出来的 $(\widehat{p})$ 。它验证的是：

$[p = p^* \quad \Longrightarrow \quad B_{\mathbb{E}}[\mathrm{KL}(\beta^* | \widehat{\beta})] \leq \frac{12}{\Phi_{\beta^*}(p^*)}]$

G0-G3 全部锁死 `allocation: oracle`，就是在验这扇门的估计器链条。

Plug-in design gate 才是 G4：在 (β) 上估全部 120 个 panel 的 (I_S) ，再用 Frank-Wolfe 得到 $(\widehat{p}(\beta))$ 。那是「一次设计是否达到 oracle 一阶效率」的完整链条。按用户决定，**这扇门先不验**。

因此「停在 G3」对**当前定义的正式 P4**是对齐的：正式格子里的 RR-GID 政策仍是 $(p^{\star})$ 。缺的是 Uniform / A-OSQD 从未上过阶梯，以及五档预算、50 次重复、正式 (J) 尚未按论文配置跑过。

风险比定义（所有阶梯同一公式，不再把设计比和风险比混在一起）：

$$[\text{risk_ratio_raw} = \frac{B \cdot \mathrm{KL}(\beta^{\star} | \widehat{\beta})}{\varphi/2}, \quad \varphi/2 = 33.6078.]$$

理想一阶效率应在 1 附近。阶梯灾难门是 **终端 (J) 的均值 < 10**，只排除几百、上千那种数值爆炸，**不是**正式效率门。

2. 一步步怎么实现（估计器本身）

下面是正式估计器在代码里实际走的路径。入口：`scripts/p4_phase3_ladder.py` 的 `run_ladder_replication`；共享逻辑在 `src/rr_gid_cn/s1_gate.py`。冻结混合物、拒绝抽样、QMC 在 `src/rr_gid_cn/synthetic_oracle.py`。

步骤 A. 冻结同一 (Q_0) 和唯一 gold 常数

1. 用固定 `mixture_seed=2026` 生成 16 维、4 分量 GMM，再加非线性 warp，得到参考测度 (Q_0) 。
2. 在这张 (Q_0) 上用高精度 QMC 算 $(\mu_{\beta^{\star}})$ 、 $(F(\beta^{\star}))$ 、每个两坐标 panel 的 $(I_S(\beta^{\star}))$ ，Frank-Wolfe 求 $(p^{\star})$ ，得到 $(\varphi = \Phi_{\beta^{\star}}(p^{\star}))$ 。
3. 独立再算一遍，相对差必须 $< 2\%$ ，前 10 个 panel 重叠 $\geq 80\%$ ， $(M(p^{\star}))$ 正定且 **Cholesky 求逆，禁止伪逆**。
4. 产物锁死：`oracle_primary.json / .npz`，hash 写进每一份后续配置。后面所有阶梯都读这份 artifact，不允许另起炉灶。

这就是 Phase 2 gold。没有这一步，后面的风险比分母都是飘的。

步骤 B. 抽一条 replication 的 target 样本

对预算 (B)、replication (r)：

- `replication_seed = 202600000 + B*1000 + r`
- `target_draw_seed = replication_seed + 3`
- 从倾斜定律抽 (B) 条完整 16 维向量（真实 GMM conditional，不是 VAEAC）。
- 这 (B) 条先切出 pilot，剩下给主分配。同一条 target 后面三个政策必须共用（正式 sweep 的配对 draws）。阶梯只跑了 oracle，所以还没有三政策配对。

步骤 C. Pilot

$$[b_B = \lceil 10 B^{1/3} \rceil.]$$

(B)	pilot (b_B)	占比
2000	126	6.3%
4000	159	4.0%
8000	200	2.5%
16000	252	1.6%
32000	318	1.0%

Pilot 在 $(p^{\star})$ 的支撑 panel 上做平衡计数（不是 120 个 panel 均分），用 Horvitz–Thompson 矩反解 $(\widetilde{\beta}=\widehat{\beta}_{\mathrm{pilot}})$ ，投影到 $(|\beta|_{\infty}\leq 4)$ 。

经验事实：这个 schedule 很 Aggressive。(B=8000) 时 (J=0)（还没做 Newton）风险比均值 **52.9**，中位 50，最大 114。Pilot 离 $(\beta^{\star})$ 很远，这是设计如此，不是实现反号。G0 已经证明：如果从 $(\beta^{\star})$ 起步，同一套 score 不会给出 50 这种数。

步骤 D. 主分配 (G0–G3 全是 oracle)

把剩余 (B-b_B) 个名额按 $(p^{\star})$ 做 largest-remainder 取整。主设计比

$$[\mathrm{design_ratio_main}=\Phi(p_{\mathrm{main}})/\Phi(p^{\star})]$$

在 oracle 下必须为 **1**（容差 (10^{-10}) ）。Pilot 会计入 `design_ratio_total_counts`，允许略大于 1。

G4 才会在 $(\widetilde{\beta})$ 上对 120 个 panel 估 (l_S) 再跑 Frank–Wolfe。已停，不展开。

步骤 E. Fisher scoring, 最多 (J) 步

每一步：

- H:** gold 当前 (β) 的 panel 信息 (G1)，或只对**当前观测里出现过的 active panel** 做交叉完备估计 (G2/G3)。 $(h_{\mathrm{tilted}}=128)$, $(h_{\mathrm{cond}}=32)$ ，条件律用 rejection。
- Score (U):** 对每条观测的 panel，算倾斜条件特征均值再减 (μ_{β}) 。G1/G2 用 gold QMC；G3a 用固定阶 QMC (order=10)；G3b 用有限 (L_U) rejection, $[L_U=\lceil 32\log_2(B+1)\rceil]$ (B=8000) 时 $(L_U=415)$ 。
- 牛顿步:** $(H=R^{\top}R)$ (Cholesky)， $(\Delta=H^{-1}U)$ ，再乘 `scoring_step_size=1`。
- 步长帽:** 若 $(|\Delta|_2>2)$ ，缩放到 2。这是 G1 无帽爆炸后补上的，与 `pilot_norm_cap=2` 对齐。G3 rejection 的 80 次更新里 **32 次撞帽**，几乎都发生在进盆前。
- 投影回 (Θ) 。记录 $(\lambda_{\min}(H))$ 、条件数、牛顿减量、raw/applied 步长。线性代数字段必须是 `cholesky_solve`。

阶梯在 $(J\in\{0,2,4\})$ (G1 还记了 1、3) 各拍一张快照。正式配置文件 `configs/p4_phase1_validation.yaml` 里写的是 `scoring_steps: 2`。两套 (J) 的合格概率差很多，第 6 节单独说。

步骤 F. 评估

用同一 (Q_0) 上的解析 KL，**禁止**把 KL 截成 0。`kl_raw` 允许的负值只到数值容差。风险比用 raw KL。oracle 时设计比必须为 1。

步骤 G. 阶梯门 (ladder_gate)

四条同时成立才 `passed`：

- 1. oracle 则所有行 `design_ratio_main == 1` ;
- 2. 所有更新 `linear_algebra == cholesky_solve` ;
- 3. `kl_raw ≥ -tolerance` ;
- 4. 终端 (J) 的 `mean risk_ratio_raw < 10`。

G0 额外要求: (J=0) 必须停在 $(\beta^{\star})$ (KL=0) 。

3. 一步步怎么实现（工程修复，按时间）

这不是改研究问题，是把审查指南里的确定性错误修掉，否则正式曲线估的是一个混了指标错误的对象。

Phase 0: 冻结，停止混跑

- 配置写死 oracle、(J=2)、预算 ({2000,8000,32000})，`not_formal: true`。
- 行级 profiler: 墙时归因 ≥ 99.87%。时间几乎全在估 H 和 conditional score，Frank–Wolfe 可忽略。
- 当时日志里的 `design_ratio` 是 3.01 / 1.06 / 5.65。那不是政策差，是旧字段把风险比当成了设计比。Phase 0 只负责拍照，不验收效率。

Phase 1: 正确性

按 `tests/test_p4_phase1.py` 的门禁修：

编号	修了什么	现在的断言
T-01	A-OSQD 的 (L_S)	嵌入的是观测块 (Σ_{SS}^{-1}) ，不是 $(\Sigma^{-1})_{SS}$
T-02	设计比 / 风险比拆开	输入 $(p^{\star})$ 时 <code>design_ratio_main==1</code> ；改分配只动 (Φ) ，不动风险比断言
T-03	exact-score 标签	finite-(L_U) rejection 不得自称 exact observed score
T-06	artifact hash	混合物 / alpha / reference / (β) / 信息方法 / commit 对不上就拒跑
T-07	seed manifest	runner 必须读 manifest，种子与行一一对应
T-08	expected grid	缺一个预算 / replication / 政策，或有重复，validator 失败
其它	pilot 参数化、 <code>use_oracle_H</code> 重命名、FW 证书	配置可复现

效果：之后所有 oracle 阶梯的 `design_ratio_main` 都精确为 1。Phase 0 那种 3–5 不再出现。

Phase 2: gold oracle + score-centering

独立重建：

量	数值	门
主 (φ)	67.216	—
复制 (φ)	65.985	相对差 < 2%
相对差	1.87%	通过
前 10 panel 重叠	100%	≥ 80%
$(M(p^{\star}))$ 最小特征值	0.00170	Cholesky
Frank–Wolfe gap	(1.6×10^{-8})	闭合

第一轮 centering 没过门（诱导风险分数 2.25，远超 1%）：条件积分不够精，非 probe 路径漏了 active_delta。这不是 φ 错，是 centering 估计器没达到证书精度。

正式 centering 证书： results/p4/allocation_cond1e4_20260831。门禁认点估计。

证书量	点估计	门
allocation 风险分数（含截断上界）	0.217%	< 1%
最难 panel (2, 8)	0.716%	< 1%
截断质量上界	(2.0×10^{-11})	可忽略
数值 SE 诱导风险	2.69%	软诊断，不挡点估计
逐 query 全收敛	未全过	不挡点估计

效果： β^* 处 gold score 的系统性偏移，相对 $\varphi/2$ ，在 $(B=32000)$ 上只贡献约千分之二的风 险。所以 G0 从 β^* 起步、 $(J=0)$ 风险比为 0，与这张证书一致。

Phase 3 阶梯：一次只加一层近似

不要直接开 $3 \times 5 \times 50$ 。失败落在哪一层，原因就在哪一层：

失败在	含义
G0	实现 / 评估反号，不是 pilot
G1	pilot / Newton 盆
G2	(H) 的有限样本近似
G3	conditional score 近似
G4	plugin 信息与设计（本次不验）

G1 无帽失败后，在 gold_oracle_start_step 加上 scoring_max_step_norm=2.0，没有改政策、预算、指标、拒绝 律。

G3 rejection 第一次死在 replication 3：远 pilot 接受率可到 (10^{-6}) ，写死 max_rounds=20000 填不满 $(L_U=415)$ 。实现上限改成按观测接受率加轮次，硬顶 200000；score 路径只累加特征均值，不存 $((N,L_U,d))$ 。 拒绝律本身没改。单测 tests/test_rejection_round_budget.py 通过。

4. 阶梯实际做了哪些实验，结果是什么

共同设置（除非另注）：gold artifact 同上；20 个 replication（诊断，不是正式 50）；oracle 分配；步长帽 2.0（无帽 G1 除外）。 $(B=8000)$ 的 $(J=0)$ 风险比在 G1–G3 逐 replication 完全相同（同一套 target + 同一套 pilot），均值 52.9195。这说明后面各层比的是「Newton 能不能把同一个很远的起点拉回来」，不是抽到了不同的 target。

4.1 G0：从 β^* 起步，排除反号

- 配置： configs/p4_phase3_g0.yaml
- $\beta^{(0)} = \beta^*$ ， $(p = p^*)$ ，冻结 gold (H)，gold score，无 pilot
- $(B=2000)$ ，20 reps， $(J \in \{0,2\})$
- 目录： results/p4/g0_b2000_20260831

(J)	均值	中位	最小	最大
0	0.000	0.000	0.000	0.000
2	0.81	0.75	0.31	1.93

(J=0) 停在 (β^*) 。两步 gold scoring 后均值仍低于 1。**实现没有反号，分母 $(\varphi/2)$ 与 score 方向对齐。** 墙时合计约 0.14 小时，可忽略。

4.2 G1 无帽：对照失败

- 实际 pilot + oracle (p^*) + **当前 (β) 的 gold (H)/score**
- $(B \in \{2000, 8000\})$, ($J=0.4$), 各 20 reps
- 目录: `results/p4/g1_20260831`
- `ladder_passed: false` , 终端 40 条均值 **73.6**

多数 replication 其实进盆了 ($(B=8000)$ 、($J=4$) 中位 1.18) , 但少数全牛顿步炸掉: 最大 **1760**, 40 条里 5 条 > 10。中位健康、均值被尾巴拉爆, 是典型的缺 trust-region, 不是算子反号。正式估计器里本来就有步长帽, ladder 第一步漏了。

4.3 G1 带帽：通过

同一套实验, 只加 `scoring_max_step_norm=2.0`。目录: `results/p4/g1_stepcap_20260831`。

预算	(J)	均值	中位	最大	< 10
2000	0	20.71	19.96	32.48	0/20
2000	2	2.46	1.83	7.06	20/20
2000	4	0.89	0.73	1.99	20/20
8000	0	52.92	50.04	114.33	0/20
8000	2	6.14	2.55	25.47	14/20
8000	4	1.24	1.00	2.91	20/20

终端 40 条合计均值 **1.06**。($J=0$ to 4) 单调进盆。**失败模式是步长，不是 gold 算子。** 墙时: 每个预算约 0.5 小时量级 (gold score 很便宜) 。

4.4 G2: 估计 H + gold score

- `h_mode: estimated` , 只对 active panel 交叉完备
- $(B=8000)$, 20 reps, ($J \in \{0, 2, 4\}$)
- 目录: `results/p4/g2_20260831`

(J)	均值	中位	最大	< 10
0	52.92	50.04	114.33	0/20
2	8.35	3.80	39.84	15/20
4	1.91	1.26	8.39	20/20

相对 G1 同格终端 1.24, 估计 H 把均值抬到 1.91、尾巴抬到 8.39, **没有毁掉 Cholesky 盆。** 墙时合计约 1.3 小时; 最慢一条约 20 分钟 (估 H 的 rejection 在远 (β) 上变肥) 。

4.5 G3 QMC: 有限 score, 第一种

- 估计 H + 固定阶 QMC score (qmc_order=10)
- 目录: results/p4/g3_qmc_20260831

(J)	均值	中位	最大	< 10
0	52.92	50.04	114.33	0/20
2	7.81	3.64	29.75	14/20
4	1.46	1.16	3.53	20/20

终端比 G2 的 gold score 还略好 (1.46 vs 1.91) 。这只能说明 **order-10 QMC 在这套 seed 上没有引入灾难性误差**，不能说 QMC 优于 gold。墙时合计约 1.22 小时，与 G2 同量级。

4.6 G3 rejection: 有限 score, 第二种 (最后一门)

- 估计 H + finite-(L_U) rejection, (L_U=415)
- 目录: results/p4/g3_rejection_20260831
- 证书: ladder_passed: true , 写于 2026-09-01 23:04 UTC
- 20/20 写完。终端均值 **1.272**, bootstrap 95% 区间 **[1.00, 1.57]**

逐 replication ((B=8000)) :

rep	(J=0)	(J=2)	(J=4)	墙时 (小时)
0	36.03	3.62	1.18	0.07
1	52.27	4.67	1.95	1.70
2	39.77	1.92	0.51	0.26
3	62.00	4.76	0.69	1.95
4	67.23	18.11	1.20	1.35
5	23.02	2.37	2.27	0.02
6	47.80	4.21	0.37	0.15
7	29.15	1.12	0.95	0.02
8	61.06	15.74	1.74	1.83
9	24.64	2.28	1.36	0.03
10	41.65	4.54	0.91	0.06
11	62.45	13.69	0.56	13.69
12	114.33	44.33	1.47	4.12
13	101.56	33.74	2.98	3.49
14	43.42	7.12	1.46	1.34
15	52.28	2.37	0.99	4.36
16	26.08	3.03	0.93	0.13
17	78.27	9.92	0.94	2.20
18	36.11	3.24	1.02	0.75
19	59.27	2.79	1.98	0.24

合计 **37.75 GPU 小时** (约 1.6 天) 。中位 replication 约 1.0 小时，最慢 13.7 小时。时间几乎全在 (J=1)-(2): (J=2) 累计均值 6746 秒，(J=4) 累计均值 6795 秒，**后两步进盆之后只要约 50 秒**。肥尾来自远 pilot 的拒绝接受率，不是线性代数。

终端 (J=4): $20/20 < 10$, $18/20 < 2$, $15/20 < 1.5$, 最大 2.98。牛顿减量从第一步的几百降到最后一步的个位数到几十。80 次更新里 32 次撞步长帽，全部在早期。

4.7 四层近似叠上去之后 (只比 (B=8000)、终端 (J=4)、20 reps)

阶梯	H	score	分配	均值	中位	最大	墙时
G1 带帽	gold 当前 (β)	gold	oracle	1.24	1.00	2.91	~0.5 h
G2	估计	gold	oracle	1.91	1.26	8.39	~1.3 h
G3 QMC	估计	QMC-10	oracle	1.46	1.16	3.53	~1.2 h
G3 rejection	估计	LU=415	oracle	1.27	1.10	2.98	37.8 h

从 (J=0) 的 53 拉到终端 1.2–1.9，是这轮实验真正做出来的效果：pilot 虽远，带帽 Fisher scoring 能进局部盆；估计 H 和两种有限 score 都没有把盆打碎。

5. 这些数字允许推出什么，不允许推出什么

可以推出：

- 评估链条 (KL、 $\sqrt{\varphi/2}$ 、Cholesky (H)、oracle 设计比) 是自洽的。
- 当前 $\lceil 10B^{1/3} \rceil$ pilot 本身不在 Newton 盆里，但 (J=4) + 步长帽 2.0 能送进去。
- 有限样本 H、order-10 QMC、LU=415 rejection 都不是当前的灾难源。
- 墙时瓶颈是远 (β) 上的条件抽样，不是 Frank–Wolfe。拒绝抽样比 QMC 贵 **三十倍** (37.8 h vs 1.2 h，同一 20 格) 。

不能推出：

- 不能说** RR-GID 已经一阶有效。门是 10，正式效率要看五档预算的 $(B \cdot \mathrm{KL})$ 是否靠近 $\sqrt{\varphi/2}$ 。
- 不能说** plugin 设计有效。G4 没跑完，正式政策里也还没有 plugin。
- 不能说** Uniform / A-OSQD 会落在哪。阶梯只跑了 oracle。A-OSQD 公式已修 (T-01)，但没在这套 gold (Q_0) 上做过 20 次诊断。
- 不能用** 20 个 replication 比较 G2 与 G3 谁更有效。两者都过灾难门即可。
- 不能**把阶梯的 replication 0–19 直接算进正式 50。同一套种子，但配置、`not_formal` 标签和 validator 网格都不同。
- 不能用**任何 `legacy_diagnostic` 旧结果当验收。

6. 正式实验大概率能不能合格

先把「合格」拆开。否则一个门过了会被说成论文过了。

6.1 工程灾难门 (均值风险比 < 10)

这是阶梯用的门，正式 validator 还要加网格完整性、artifact hash、配对 draws。只谈风险比均值。

若正式终端是 (J=4)，且带步长帽 2.0，政策是 oracle RR-GID，预算含 (B=8000)：

20/20 已经 < 3，均值 1.27，bootstrap 95% 在 [1.00, 1.57]。再抽 30 个同类 replication，均值跳到 10 以上的概率可以忽略。

判断：几乎肯定过。

若正式仍按 configs/p4_phase1_validation.yaml 用 (J=2)：

G3 rejection 在 (B=8000)、(J=2) 的均值是 9.18，20 条里 5 条 > 10，最大 44.3。对这 20 个数做 bootstrap，均值的 95% 区间是 [5.0, 14.7]，已经跨过 10。50 次重复会把区间收窄，但期望仍在 9 附近；若 (B=16000/32000) 的相对 pilot 更小，(J=2) 可能更差。

判断：勉强，不是大概率。(B=8000) 可能贴着门过，更大预算没有证书。

这是目前最重要的配置风险。论文 Algorithm 2 写 (J=2)；阶梯为了看进盆，把终端放到了 (J=4)。两步时多数 replication 还在盆外 (中位 4.4，不是 1.1)。不改政策的前提下，正式若坚持 (J=2)，不能把 G3 终端 1.27 抄过去当预测。

步长帽：正式 yaml 里 scoring_max_step_norm 仍是 null。G1 无帽已经演示过均值 73、最大 1760。开正式之前必须把已经验证过的帽 2.0 写进 runner。这不是改指标，是把估计器里已有的 trust-region 打开。

Uniform / A-OSQD：没有阶梯数字。理论上风险比应高于 oracle (设计更差)。它们仍可能过灾难门 (门很松)，但「oracle 明显更好」才是论文故事，那要等正式格子，不能用 G3 外推。

6.2 正式效率门 (风险比靠近 1，随 (B) 下降)

G0 在 (B=2000)、无 pilot、(J=2) 均值 0.81，说明评估器可以报出低于 1 的数。
G3 在有 pilot、(B=8000)、(J=4) 均值 1.27、中位 1.10，已经在 1 的附近，但仍是单档预算、20 次、oracle-only。

五档预算上是否单调靠近 1：未知。Pilot 占比随 (B) 下降 (6.3% → 1.0%)，大预算的 (J=0) 只会更远；若正式 (J=2)，大预算更可能停在盆外，效率曲线会看起来像理论失败，其实是步数不够。若正式 (J=4) + 帽，从现有隔离结果看，oracle 政策有合理机会给出一条可写进论文的下降曲线，但不是已经证明。

6.3 合格概率汇总 (在「不改政策、预算、指标」的前提下)

场景	概率判断	依据
正式 yaml 补上帽 2.0，终端 (J=4)，oracle 灾难门	很高	G3 均值 1.27，20/20 < 3
同上，oracle 效率看起来靠近 1	中高	单档 1.27；缺 16000/32000
正式保持 (J=2) + 帽，oracle 灾难门	中低	(J=2) 均值 9.18，bootstrap 已跨 10
正式保持 (J=2) 且无帽	极低	G1 无帽均值 74
Uniform / A-OSQD 灾难门	未知，偏能过	门松，但没跑过
Uniform / A-OSQD 效率接近 oracle	低 (也不该接近)	理论设计比 > 1
不经验证就宣称 plugin 一阶有效	不允许	G4 已停

对用户问题的直接回答：

若把「合格」理解成「oracle 估计器不会再数值爆炸、可以开 50 次正式格子」，G3 已经足够支持开跑，前提是带上步长帽，并想清楚正式 (J) 是 2 还是 4。

若把「合格」理解成「论文效率门会过」，(J=4) 时大概率值得跑；(J=2) 时应该先预期曲线难看，而不是预期理论被证伪。

7. 后面还要算多久

单卡 4080 SUPER。下面用 G3 的实测墙时外推，不发明加速比。工作量粗算：条件抽样次数 $(B \cdot L_U \cdot J)$ 接受率。接受率在远 pilot 上是肥尾，所以大预算会比纯体积比更贵。

$(L_U = \lceil 32 \log_2(B+1) \rceil)$:

(B)	(L_U)	(B · L_U) 相对 8000
2000	351	0.21
4000	383	0.46
8000	415	1
16000	447	2.15
32000	479	4.62

五档合计相对「只跑 (B=8000)」约 **8.4 倍体积**。50/20 = 2.5 倍重复。3 个政策若共享 target、但 H/score 各算一遍，再 ×3。拒绝抽样的时间几乎全在前两步，所以正式即使用 (J=2)，也 **省不了多少墙时**。

7.1 正式 P4 sweep (3 × 5 × 50 = 750 格)

锚定：G3 rejection 在 1 政策 × 1 预算 × 20 次 × (J=4) = **37.8 小时**。G3 QMC 同样格子 = **1.22 小时**。

路径	算法	估时 (单卡, 连续跑)
A. 现在这套 rejection, 不做性能重构	有限 LU 拒绝	约 60–100 天 (中位按体积比约 33 天/政策 ×3, 再加 (B=32000) 更肥的尾)
B. 先做 Phase 4, 正式走 QMC 大规模路径	与 G3 QMC 同阶	约 3–8 天 (1.22 h × 2.5 × 8.4 × 3 ≈ 77 h, 再加 Uniform/A-OSQD 的设计开销和排队)
C. 混用: 小预算 rejection 证书 + 大预算 QMC	审查指南允许的分层	约 2–4 周 , 取决于哪些格必须 unbiased

路径 A 不推荐。G3 已经证明 rejection 在 (B=8000) 就要 1.6 天/20 次，正式是它的几十倍。

7.2 Phase 4 性能重构 (正式之前强烈建议先做)

审查指南的优先级: shared pilot、缓存 reference 特征、第一步共享信息、按 panel 分组观测、rejection 自适应提案、**fixed-QMC 大规模模式**、一卡一进程、memmap。

这是工程，不是 50 次论文格子。人时大约数天到一周；中间会有固定 seed 对照跑 (单 replication / 小预算)，GPU 再加 **0.5–2 天**。不做这一步就开路径 A，会把后续所有阶段锁在拒绝抽样上。

7.3 Phase 5: pilot 指数

$(\gamma \in \{1/3, 0.4, 1/2\})$ ，锚定 $(B \in \{2000, 8000, 32000\})$ ，先 50 次。格子大约是正式 sweep 的 2/5 (3×3×50 vs 3×5×50，若仍是三政策；指南写的是先把 exponent 和样本量分开)。

QMC 路径大约 **1–3 天**；rejection 路径大约 **2–4 周**。

7.4 P4 之后（论文后半，不是现在）

P4 正式锁住以前不应开。量级如下，避免误以为 G3 之后就只剩出图：

阶段	内容	算力量级
P5	Discriminative + learned RR-GID，四政策	重（含 MLP）
P6	Synthetic VAEAC 训练与冻结	中重
P7	S2 alpha / reuse	重
P8	Gas 预处理	轻
P9 / P10	Gas R1/R2，50 次配对	重
P11 / P12	出图、hash、冻结	几乎不吃 GPU

7.5 若只关心「停在 G3 之后，最短何时能看到正式 P4 数字」

- 1. 把正式 runner 的步长帽写成 2.0；明确正式 (J) (2 或 4) 。不改预算、政策、指标。
- 2. 做 Phase 4 的 QMC 大规模路径（3-7 天工程 + 对照）。
- 3. 开 3×5×50。QMC 下再 **约一周** 出齐。

从今天起，**最快大约两周看到正式 P4 全表**；若坚持 rejection、不改 (J)、不做 Phase 4，则按 **季度** 估。

8. 证书目录与复现入口

本机：

- Gold: results/p4/phase2_gold_full116_20260827
- Centering: results/p4/allocation_cond1e4_20260831
- G0: results/p4/g0_b2000_20260831
- G1 无帽对照: results/p4/g1_20260831
- G1 带帽: results/p4/g1_stepcap_20260831
- G2: results/p4/g2_20260831
- G3 QMC: results/p4/g3_qmc_20260831
- G3 rejection: results/p4/g3_rejection_20260831

远程 G3 rejection 原目录： /root/autodl-tmp/rr_g3/g3_rejection_20260831。G4 目录保留但不验收。

配置： configs/p4_phase3_g0.yaml 与 configs/p4_phase3_g{1,2,3_qmc,3_rejection}.yaml。阶梯入口： scripts/p4_phase3_ladder.py。正式入口（尚未跑）： scripts/p4_formal_run.py，manifest experiments/p4_target_draw_manifest.json（5×50=250 条配对种子）。

基线 commit: d43add31。工作区有未提交修改；证书里的 source_sha256 以各 diagnostics.json 为准。G3 rejection 的 synthetic_oracle.py hash 为 16088be7...（含 round-budget 实现上限）。

9. 结论

G4 已停。P4 诊断链停在 G3： oracle 分配下，估计 H + 有限 score 过了均值 < 10 的灾难门，终端风险比 1.27。这支持「实现和近似层没有把理论对象算爆」，也支持在补上步长帽、想清楚 (J) 之后去开正式 50 次。

它 **不** 支持现在就写「RR-GID 一阶有效」，也 **不** 支持跳过 Phase 4 用拒绝抽样去扛 750 格。正式合格的大概率成立，主要建立在 **(J=4) + 帽 2.0 + oracle 政策** 上；若正式仍是 (J=2)，需要先接受「均值可能贴着 10、大预算可能更差」，而不是期待再出现 1.27。