

P4 已完成实验进度汇报

Phase 0–2 通过，Phase 3 阶梯已到 G3 QMC

2026年8月31日 | 诊断实验，非正式 replication sweep

本文只汇报**已经写完证书、可以下结论**的实验。所有 Phase 3 阶梯运行都标了 `not_formal: true`，工程灾难门是「终端风险比均值 < 10 」，**不是**正式效率门（风险比趋近 1）。正式 200-replication sweep、Phase 4 性能、Phase 5 pilot 比较都还没开。

一句话结论： 实现符号、归一化、Cholesky H 和理论常数是对的；pilot 离 β^* 很远，但带步长帽的 Newton 能拉回盆内。估计 H 和 QMC score 都没有把阶梯打爆。当前卡在 G3 有限 LU rejection (3/20)，其后才是 G4 plugin 设计。

1. 总览

阶段	状态	关键结果
Phase 0 冻结与 profiler	通过	墙时归因 $\geq 99.87\%$ ；禁止把未校验输出叫 formal
Phase 1 正确性修补	通过	设计比与风险比拆开；oracle 主设计比必须为 1；单元测试全过
Phase 2 gold oracle	通过	$\varphi/2 = 33.608$ ；独立重建相对差 1.87%（门 2%）
Phase 2 score-centering	通过（点估计）	allocation 诱导风险 0.217% （门 1%）
G0 oracle-start	通过	$J=0$ 停在 β ； $J=2$ 风险比均值 0.81*
G1 gold H / score	通过（带帽）	终端 40 条均值 1.06 ；无帽会爆炸，属 basin 而非反号
G2 估计 H + gold score	通过	$B=8000, J=4$ 均值 1.91 ， $20/20 < 10$
G3 QMC score	通过	$B=8000, J=4$ 均值 1.46 ，最大 3.53
G3 rejection score	进行中	3/20；已完成终端均值 1.21
G4 plugin 设计	未开始	需 G3 两门都过

机器：开发机单卡 RTX 4080 SUPER 32GB。Gold 基线：`results/p4/phase2_gold_full116_20260827`。理论常数 $\varphi/2 = 33.6078$ 。Pilot 与 Phase 1 相同： $\lceil 10 B^{1/3} \rceil$ 。

2. Phase 0–1：先把账算清

● Phase 0：可复现、可归因，不再混跑

固定 seed、只跑 oracle 分配、 $J=2$ 、预算 {2000, 8000, 32000}。最低墙时归因 **99.87%**。时间几乎全在估计 H 和 conditional score，线性代数可忽略。

当时的 `design_ratio` 在三档预算上分别是 3.01 / 1.06 / 5.65。这不是政策差，而是**旧指标把设计比和风险比混在一起**。Phase 0 只负责冻结现场，不据此验收效率。

● Phase 1：明确 bug 已修

按审查指南顺序修完：A-OSQD 信息、设计比/风险比拆分、raw KL 校验、pilot 参数化、seed manifest、artifact hash、expected-grid、FW 证书、`use_oracle_H` 重命名。对应 `tests/test_p4_phase1.py` 等门禁测试通过。

效果： 之后所有 oracle 分配阶梯的 `design_ratio_main` 都精确为 **1**。Phase 0 那种 3-5 的「设计比」不再出现。

3. Phase 2：同一 Q₀ 下的 gold 常数

冻结唯一 oracle artifact 和唯一理论常数。独立重建：

量	数值	门
主 φ	67.216	—
复制 φ	65.985	相对差 < 2%
相对差	1.87%	通过
前 10 panel 重叠	100%	$\geq 80\%$
M(p*) 最小特征值	0.00170	Cholesky, 不用伪逆
Frank-Wolfe gap	1.6×10^{-8}	证书闭合

Gold 构件上的第一轮 score-centering **没有过门** (allocation 风险分数 2.25, 远超 1%)。原因是条件积分精度不够, 以及非 probe 路径漏了 `active_delta`。这不是理论常数错, 是 centering 估计器没达到证书精度。

● 正式证书：allocation, cond 10^{-4}

目录：`results/p4/allocation_cond1e4_20260831`。门禁认**点估计**；T-04 逐 query 全收敛只做诊断。

证书量	点估计	门
allocation 风险分数 (含截断上界)	0.217%	< 1%
最难 panel (2, 8)	0.716%	< 1%
截断质量上界	2.0×10^{-11}	可忽略
数值 SE 诱导风险	2.69%	软诊断, 不挡点估计门
逐 query 全收敛	未全过	不挡点估计门

效果： β 处 gold score 的系统性偏移, 相对于 $\varphi/2$, 在最大预算上只贡献约千分之二风险。后面 G0 能从 β 起步且 J=0 风险比为 0, 与这张证书一致。

4. Phase 3 阶梯：效果怎么读

阶梯的目的是**隔离**失败原因, 不是直接报效率。

若失败在	含义
G0	实现/评估反号，不是 pilot 问题
G1	pilot / Newton 盆
G2	H 的有限样本近似
G3	conditional score 近似
G4	plugin 信息与设计

共同验收：oracle 时 `design_ratio_main = 1`；H 用 Cholesky；raw KL 不低于数值容差；终端 J 的风险比均值 < 10。

风险比定义为 $B \cdot KL(\beta^* \parallel \hat{\beta}) / (\varphi/2)$ 。理想一阶效率应在 1 附近；当前门 10 只排除几百、上千那种数值爆炸。

● G0：符号和常数是**对**的

$\beta^{(0)} = \beta$, $p = p$, 冻结 gold H, gold score, 无 pilot。B=2000, 20 reps, $J \in \{0, 2\}$ 。

J	风险比均值	中位	最小	最大
0	0.000	0.000	0.000	0.000
2	0.81	0.78	0.31	1.93

J=0 停在 β ($KL = 0$)。两步 gold scoring 后均值仍低于 1，说明 score 方向、 H^{-1} 和 $\varphi/2$ 对齐。实现没有反号。*

● G1 无帽失败，带帽通过

实际 pilot + oracle p + 当前 β 的 gold H / score*。J = 0..4, $B \in \{2000, 8000\}$ ，各 20 reps。

Pilot 本身很远：J=0 风险比均值 20.7 (B=2000) 和 52.9 (B=8000)。这是 $\lceil 10 B^{1/3} \rceil$ pilot 的预期，不是 bug。

无帽时多数 replication 进盆 (J=4 中位数约 1.20)，但少数全步长爆炸：终端 40 条里 5 条 > 10、4 条 > 100，最大 **1760**，均值被拉到 73.6，门失败。正式估计器已有 trust-region, ladder 第一步漏了。

补上 `scoring_max_step_norm = 2.0`（与 `pilot_norm_cap` 对齐）后重跑：

预算	J	均值	中位	最大	< 10
2000	0	20.71	20.28	32.48	0/20
2000	2	2.46	1.96	7.06	20/20
2000	4	0.89	0.73	1.99	20/20
8000	0	52.92	52.27	114.33	0/20
8000	2	6.14	2.82	25.47	14/20
8000	4	1.24	1.02	2.91	20/20

终端 40 条合计均值 **1.06**。J = 0 → 4 单调下降，符合 Newton 进盆。**失败模式是步长，不是 gold 算子反号。**

● G2：估计 H 还能**进**盆

实际 pilot + oracle 分配 + **估计 H** (active-panel 交叉完备, rejection) + gold score。只跑 B=8000, 20 reps, $J \in \{0, 2, 4\}$ 。

J	均值	中位	最大	< 10
0	52.92	52.27	114.33	0/20
2	8.35	3.81	39.84	15/20
4	1.91	1.40	8.39	20/20

相对 G1 同预算终端 1.24，估计 H 把均值抬到 1.91、尾巴抬到 8.39，但仍全部低于灾难门。**有限样本 H 有代价，没有毁掉 Cholesky 盆。**

● G3 QMC: 有限 score 也没爆

在 G2 上把 score 换成固定阶 QMC (qmc_order=10)，H 仍是估计。B=8000，20 reps。

J	均值	中位	最大	< 10
0	52.92	52.27	114.33	0/20
2	7.81	3.66	29.75	14/20
4	1.46	1.22	3.53	20/20

终端比 G2 的 gold score 还略好 (1.46 vs 1.91，最大 3.53 vs 8.39)。这只能说明 **order-10 QMC 在这套 seed 上没有引入灾难性 score 误差**，不能解读成 QMC 优于 gold；gold 路径不同、方差也不同。隔离结论成立：conditional score 的 QMC 近似不是当前瓶颈。

● G3 rejection: 还在跑

同一套 H，score 改为有限 LU rejection (LU = [32 log₂(B+1)] = 415)。截至汇报时 **3/20** 写完，进程仍在跑。已完成三条终端风险比 1.18 / 1.95 / 0.51，均值 1.21。单 replication 耗时极不均匀 (约 4 分钟到 100 分钟)，卡在远离 β* 时的低接受率，不是死锁。

G4 (plugin $\hat{p}(\hat{\beta})$)，估计全部 120 个 panel 的 I₅) 要等 G3 两门都过。

5. 阶梯对照：近似一层层加上去之后

下表只比较 **B=8000、终端 J=4、20 reps** (G1 带帽；G0 无此格，因只跑了 B=2000, J=2)。

阶梯	H	score	分配	风险比均值	中位	最大
G1 带帽	gold 当前 β	gold	oracle	1.24	1.02	2.91
G2	估计	gold	oracle	1.91	1.40	8.39
G3 QMC	估计	QMC-10	oracle	1.46	1.22	3.53
G3 rej.	估计	LU=415	oracle	1.21 (3/20)	—	—

G0 (B=2000, J=2, 从 β 起步) 均值 0.81，说明评估链条本身可以低于 1*，不是「已经达到正式效率」。从 G1 的 J=0 均值 53 拉到终端约 1.2–1.9，才是这轮实验真正做出来的效果：当前 pilot 虽远，带帽 Fisher scoring 能把估计器送进局部盆。

6. 不要从这些数字推出的结论

- 不能说 RR-GID 已经一阶有效。门是 10，正式效率要等 G4 过后再开 full sweep。
- 不能用 Phase 0 的 design_ratio 或任何 legacy_diagnostic 旧结果当验收。

- **不能**把 G1 无帽爆炸读成实现反号。G0 已排除；爆炸是无 trust-region 的全牛顿步。
- **不能**用 20 个 replication 比较 G2 与 G3 QMC 谁更有效。两者都过灾难门即可。
- Score-centering 的 2.69% 数值 SE 风险是软诊断；点估计 0.217% 才是过门依据。

7. 下一步

1. 等 G3 rejection 20/20 写完并过门（远程 `/root/autodl-tmp/rr_g3/g3_rejection_20260831`）。
2. 跑 G4 plugin：报告真正的 `design_ratio_main`（不再锁成 1）。
3. G0–G4 全过之后，才允许恢复正式 replication、Phase 4 性能重构、Phase 5 pilot schedule。

本机备份目录：`results/p4/g0_b2000_20260831`、`g1_stepcap_20260831`、`g2_20260831`、`g3_qmc_20260831`、`allocation_cond1e4_20260831`。无帽 G1 保留在 `g1_20260831`，仅作对照，不作为通过证书。