

正式 P4 慢在哪、大概要多久

依据 Phase 0 行级 profiler 与 G3 实测墙时，单卡外推

2026年9月2日
非正式 · 诊断证书

一句话

慢的不是 Frank-Wolfe，也不是解线性方程。每一次更新 β 都要重算 **观测信息 H** 和 **conditional score**，两者都卡在 GMM 缺失坐标的条件抽样上。拒绝抽样在远离 β^* 时接受率会掉到 10^{-3} 乃至 10^{-6} ，时间几乎全在进 Newton 盆之前的前两步。

G3 rejection 同格 37.8 GPU 小时	G3 QMC 同格 1.2 小时 · 快 30 倍	正式格子 $3 \times 5 \times 50 = 750$	外推机器 RTX 4080 SUPER
--------------------------------	------------------------------	--------------------------------------	------------------------

01 哪一环节慢

吃掉几乎全部墙时

- 估 H：当前 β 上的 Fisher / 观测信息
- 算 conditional score：更新方程里的条件得分
- 两者都要对缺失坐标做 GMM 条件抽样

几乎可以忽略

- Frank-Wolfe（正式 P4 用 oracle p^* ，设计步甚至是 0）
- 解 $H^{-1}s$ 、建 pilot、反解 β
- 抽完整 target、算 KL

Phase 0 在 A800 上拍过一格：oracle 分配、 $B = 8000$ 、 $J = 2$ 、1 次 replication。墙时归因 **99.79%**，合计 12.4 秒。时间切分如下。

H 56%		score 32%		KL 7%	其余
■ 估 H	■ conditional score	■ KL	■ 抽 target / μ / pilot		
环节	秒	占比	说明		
估 H	6.91	55.7%	当前 β 上重估观测信息，内层是条件抽样		
conditional score	4.01	32.3%	更新方程，同样是条件抽样		
KL	0.91	7.3%	评估用，不进更新循环		
抽完整 target	0.34	2.7%	倾斜定律抽 B 条完整向量		
μ / pilot 反解	0.20	1.6%	一次		
Frank-Wolfe / 线性代数	≈ 0	$< 0.1\%$	不是瓶颈		

该格还记下：条件提案约 14.8 亿次，接受约 580 万次，中位接受率 0.30%，最低 0.10%。720 次拒绝调用。Phase 0 说明「时间花在哪」；G3 才说明「远 pilot 上会有多肥的尾」。

02 为什么拒绝抽样特别贵

条件抽样次数大致正比于 $B \cdot L_U \cdot J / \text{接受率}$ 。 $L_U = \lceil 32 \log_2(B+1) \rceil$ ， $B = 8000$ 时 $L_U = 415$ 。接受率在远离 β^* 时是肥尾：普通格 10^{-3} 量级，G3 最差 replication 可到 10^{-6} ，写死的轮次上限曾经填不满 L_U （后来按观测接受率加轮次，硬顶 200000；拒绝律本身没改）。

G3 rejection: $B = 8000$ 、20 次、 $J = 0 \dots 4$ ，合计 **37.8 GPU 小时**（约 1.6 天）。中位 replication 约 1 小时，最慢一条 **13.7 小时**。时间几乎全在进盆前：

做到哪一步	累计均值 (秒)	含义
$J = 2$	6746	约 1.9 小时已经花完；这就是进盆前的前两步
$J = 4$	6795	后两步进盆之后只要约 50 秒

正式配置写成 $J = 2$ 也省不了多少

贵的就是前两步。进盆之后 β 靠近 β^* ，接受率回升，后面的 Fisher scoring 很快。QMC 同格只要 1.2 小时，比拒绝抽样快约 30 倍，是因为绕开了「远 β 上提案几乎全被拒」这条尾巴，不是因为少算了 H 或 score。

03 正式 P4 外推多久

正式格子：Uniform / A-OSQD / oracle RR-GID，预算 {2000, 4000, 8000, 16000, 32000}，每格 50 次，共 750 格。五档预算相对只跑 $B = 8000$ 约 **8.4 倍体积** ($B \cdot L_U$)， $50/20 = 2.5$ 倍重复，三个政策各算一遍 H/score 再 $\times 3$ 。大预算上拒绝抽样还会更肥，所以不能只乘体积比。锚定：G3 rejection 同格 37.8 小时，G3 QMC 同格 1.22 小时。

路径	算法	单卡连续跑
A. 现在这套拒绝抽样	有限 L_U 拒绝	约 2–3 个月 (约 60–100 天)
B. 先做性能重构，正式走 QMC	与 G3 QMC 同阶	约 3–8 天 GPU (约 77 小时再加排队)
C. 小预算拒绝 + 大预算 QMC	审查指南允许的分层	约 2–4 周

路径 B 的 GPU 粗算： $1.22 \text{ h} \times 2.5 \times 8.4 \times 3 \approx 77 \text{ h}$ 。从今天起，若先花几天做 QMC 大规模路径再开格子，最快大约两周出齐正式全表。G4 若审核要求先过，会再加一段 plugin 扫 120 个 panel 的 I_5 ，主耗时仍是正式 750 格。

墙时瓶颈已经定位：远 pilot 上的 H 与 conditional score 条件抽样，不是设计步。正式 P4 走拒绝抽样按月计，走 QMC 按天计。现在停在 G3，是为了先审核选哪条路径，避免一开就锁在几十天的拒绝抽样上。