

现在做了什么、做到哪里

P4 正在进行正式实验前的诊断阶梯，已做到 G3

2026年9月2日
非正式 replication · 20 次诊断

P0–P3 底座完成 P4 诊断阶梯做到 G3 G4 / 正式 50 次 · 待审核

现在停在这里

论文阶段 **P0–P3 工程底座已完成**。P4 正在进行正式实验前的诊断阶梯 **G0 → G1 → G2 → G3**（QMC 与 rejection 两门都过）。G4 与正式 3 政策 × 5 预算 × 50 次先停，等审核后再跑。P5 之后尚未开始。所有 G0–G3 均标 `not_formal: true`，还不是论文里的 50 次正式结果。

机器 RTX 4080 SUPER 32GB	Gold 常数 $\varphi/2$ 33.6078	Pilot [10 B^{1/3}]	正式 replication 50 · 禁止 200
--------------------------------------	---------------------------------------	--------------------------------------	--------------------------------------

G0
已过

 →

G1
已过

 →

G2
已过

 →

G3
当前停此

 →

G4
待审核

 →

正式
3×5×50

01 全项目地图

两套编号不要混：P0–P12 是论文全流程；G0–G4 是 P4 正式实验前的诊断阶梯，当前做到 G3。

论文阶段	要交付什么	现在
P0 环境与入口	目录、seed、pytest smoke	完成
P1 Synthetic exact oracle	冻结 GMM+warp、精确条件抽样、KL / F / I _S	完成
P2 三种分配政策	Uniform、A-OSQD、oracle RR-GID、Frank–Wolfe	完成
P3 Pilot–Design–Update	Algorithm 2: pilot、HT、交叉完备、Fisher scoring	完成 toy / 可复现
P4 Synthetic S1	三政策、五档预算、50 次，看 B•KL 是否靠近 $\varphi/2$	诊断至 G3 G4 与正式格子待审核
P5 四政策 Fig.1	加上 Discriminative	未开始
P6–P7 VAEAC 与 S2	生成器与 reuse	未开始
P8–P10 Gas	真实漂移	未开始
P11–P12 出图冻结	只读已锁结果	未开始

唯一依据：核心文档/RR_GID_CN.pdf 与 P4 审查指南。legacy_diagnostic_20260826/ 不作验收、不作论文数字。

02 P4 之前：P0–P3

这四步是把算法装进代码，不是论文主表。

P0 环境

固定工作区、配置入口、随机源和测试能跑通。没有这一步，后面所有 seed 对不上。

P1 Synthetic oracle

按 PDF 用 seed 2026 冻结 16 维、4 分量 GMM，再加非线性 warp，得到参考测度 Q₀。实现任意两坐标 panel 的解析条件高斯混合、倾斜抽样、特征映射 φ 、配分、 μ_β 、Fisher F、panel 信息 I_S、目标 KL。这一阶段不用 VAEAC，条件律是精确的。评估原语齐了，后面风险比的分母 φ 从这里来。

P2 三种政策

- Uniform SQD: 120 个 panel 均分;
- A-OSQD: Jang 的 A-optimal split-questionnaire;
- oracle RR-GID: 用 F, I_S 做 Frank–Wolfe, 得到 p^* 。

同时实现成本感知取整和预算账。三个政策能吐出可审计的分配。

P3 整条 Algorithm 2

把 PDF 的 Pilot–Design–Update 串起来: 平衡 pilot、Horvitz–Thompson 矩、反解 $\hat{\beta}$ 、交叉完备估 I_S 、一次设计、主实验、 J 步 Fisher scoring, 投影回 Θ 。固定 seed 的小预算玩具能从头跑到 $\hat{\beta}$ 。大预算下是否一阶有效, 是 P4 的事。

03 P4 正在做什么

规划里的正式 P4 是: Uniform / A-OSQD / oracle RR-GID, 预算 {2000, 4000, 8000, 16000, 32000}, 每格 50 次, 看 B·KL 是否靠近 $\varphi/2$ 。

正式格子开跑之前, P4 先走诊断阶梯, 一次只加一层: **G0** → **G1** → **G2** → **G3** (已过) → G4 (先停, 待审核) → 正式 3×5×50 (先停, 待审核)。

Gold 基线已冻结: $\varphi = 67.216$, $\varphi/2 = 33.608$, 独立重建相对差 1.87% (门 2%)。oracle 分配下主设计比为 1。后面 G0–G3 都读同一份 artifact。

04 诊断阶梯怎么读

阶梯的目的是一次只加一层。共同工程门: oracle 时设计比 = 1; H 用 Cholesky; raw KL 不低于容差; **终端风险比均值 < 10**。门 10 只排除爆炸, 不是效率 1。

风险比 = $B \cdot \text{KL}(\beta^* \parallel \hat{\beta}) / (\varphi/2)$, $\varphi/2 = 33.6078$

阶梯	这一层新加入的东西	状态
G0	从真值 β^* 起步, 无 pilot	已过
G1	真实 pilot + gold H + gold score	已过 带步长帽
G2	把 gold H 换成有限样本估计 H	已过
G3	再把 gold score 换成有限 score	已过 QMC 与 rejection
G4	再用 $\hat{p}(\hat{\beta})$ 换掉 p^*	待审核后再跑

G1–G3 全部锁死 oracle 分配。B = 8000 时 J = 0 (还没 Newton) 的风险比均值在 G1–G3 都是 **52.92**, 逐 replication 相同: 比的是同一个很远的起点能不能拉回来。

05 G0: 符号和常数是对的

做了什么。 $\beta^{(0)} = \beta^*$, $p = p^*$, 冻结 gold H, gold score, 关掉 pilot。B = 2000, 20 次, $J \in \{0, 2\}$ 。

J	均值	中位	最大
0	0	0	0
2	0.81	0.75	1.93

J = 0 停在真值上。两步 gold scoring 之后均值仍低于 1。后面若出现风险比 50、1000, 不能解释成算子写反或分母除错。

06 G1：真实 pilot + 全 gold 算子

这一层新加入什么。第一次用论文里的 aggressive pilot $[10 B^{1/3}]$ 。分配仍是 p^* 。每一步的 H 和 score 都用当前 β 上的 gold 条件期望。预算 $B \in \{2000, 8000\}$ ，20 次，拍 $J = 0, 1, 2, 3, 4$ 。

无帽时少数全牛顿步炸掉（终端均值 73.6，最大 1760）。加上步长帽 2.0 后通过。没有改政策、预算、指标。

预算	J	均值	中位	最大	< 10
2000	0	20.71	19.96	32.48	0/20
2000	2	2.46	1.83	7.06	20/20
2000	4	0.89	0.73	1.99	20/20
8000	0	52.92	50.04	114.33	0/20
8000	2	6.14	2.55	25.47	14/20
8000	4	1.24	1.00	2.91	20/20

终端 40 条合计均值 **1.06**。J = 0 $\rightarrow$ 4 单调下降。Pilot 本身很远（B = 8000、J = 0 均值 53），但带帽 Fisher scoring 能送进局部盆。J = 2 时 B = 8000 均值仍是 6.14，两步往往还在盆外。

对照 results/p4/g1_20260831 · 证书 results/p4/g1_stepcap_20260831

07 G2：换成估计 H

其它与 G1 带帽相同，只把每步的 gold H 换成 active panel 上的有限样本交叉完备。Score 仍是 gold。只跑 B = 8000，20 次，J $\in \{0, 2, 4\}$ 。

J	均值	中位	最大	< 10
0	52.92	50.04	114.33	0/20
2	8.35	3.80	39.84	15/20
4	1.91	1.26	8.39	20/20

有限样本 H 有代价（相对 G1 终端 1.24 $\rightarrow$ 1.91），但没有毁掉盆，20/20 低于灾难门。墙时约 1.3 小时。

results/p4/g2_20260831

08 G3：再换成有限 score • 当前停在这里

H 继续用 G2 的估计。Score 不再用 gold，分别换成：固定阶 QMC（order = 10）；有限 $L_U = \lceil 32 \log_2(B+1) \rceil = 415$ 的拒绝抽样。仍是 oracle 分配，B = 8000，20 次，J $\in \{0, 2, 4\}$ ，步长帽 2.0。

G3 QMC

J	均值	中位	最大	< 10
0	52.92	50.04	114.33	0/20
2	7.81	3.64	29.75	14/20
4	1.46	1.16	3.53	20/20

墙时约 **1.2 小时**。order-10 QMC 没有引入灾难性误差。

G3 rejection

J	均值	中位	最大	< 10
0	52.92	50.04	114.33	0/20
2	9.18	4.37	44.33	15/20
4	1.27	1.10	2.98	20/20

终端 bootstrap 95% 区间 [1.00, 1.57]。合计 **37.8 GPU 小时** (约 1.6 天) ; 中位 replication 约 1 小时, 最慢 13.7 小时。时间几乎全在进盆前的 $J = 1-2$ 。两种有限 score 都没有把盆打碎。G3 对应正式 P4 里 oracle RR-GID 要用的估计器。

results/p4/g3_qmc_20260831 · results/p4/g3_rejection_20260831

09 G1 / G2 / G3 对照 • B = 8000, 20 次

	新加入	J=4 均值	J=4 最大	J=2 均值	墙时
G1 带帽	真实 pilot, 算子全 gold	1.24	2.91	6.14	~0.5 h
G2	估计 H	1.91	8.39	8.35	~1.3 h
G3 QMC	QMC score	1.46	3.53	7.81	~1.2 h
G3 rejection	$L_0=415$ score	1.27	2.98	9.18	37.8 h

一层层换成正式估计器会用的近似之后, $J = 4$ 一直停在 1.2–1.9, 灾难门过了。实现没有在近似层上炸掉。

10 根据 G1–G3, 对 G4 和正式 P4 的判断

判断

G4 和正式 P4 大概率能跑成功。现在先停下来审核, 而不是因为阶梯失败。

- G0 排除了反号和常数错误。
- G1 说明远 pilot 加带帽 Newton 能进盆, 终端风险比约 1。
- G2 说明换成估计 H 仍进盆 (终端 1.91, $20/20 < 10$) 。
- G3 说明换成正式会用的有限 score 仍进盆 (QMC 1.46, rejection 1.27, 最大都低于 4) 。
- 正式 P4 的 oracle RR-GID 就是 G3 这条链, 只是预算从 1 档变成 5 档、重复从 20 变成 50、再加 Uniform / A-OSQD。G4 只是在同一条 scoring 链上把 p^* 换成 $\hat{p}(\hat{\beta})$, 多一步设计, 不是另一套估计器。

因此: 数值上大概率不会再出现 G1 无帽那种爆炸; 估计器和近似层已经过了灾难门。正式效率曲线是否漂亮、Uniform / A-OSQD 相对 oracle 差多少, 仍要正式格子才能下结论, 但「跑不完 / 跑爆」不是当前的主风险。

当前主风险是墙时, 不是过不过门

G3 rejection 单档 B = 8000、20 次就要 1.6 天, 最慢一条 13.7 小时。G4 还要在远 pilot 上扫 120 个 panel, 只会更长。正式 $3\times5\times50$ 若继续拒绝抽样, 按天到按月计; 走 QMC 大规模路径则大约数天到一周。所以先审核路径、J、是否先做性能重构, 再决定开 G4 还是直接开正式格子。

后面	成功把握	为什么先停
G4 plugin	大概率能过灾难门	同一套估计器, 只多设计一步; 但比 G3 更肥尾, 要先确认值得花这些天
正式 P4 50 次	大概率能跑完且 oracle 不爆炸	格子是 G3 的几十倍; 拒绝抽样可能要一到三个月, QMC 则短得多, 需要审核选哪条

P0–P3 底座齐了。P4 正在进行正式实验前的诊断阶梯, 已经走完 $G0 \rightarrow G1 \rightarrow G2 \rightarrow G3$ 。根据这三层, G4 和正式 P4 大概率能跑成功; 现在停下来, 是因为后面墙时会很长, 先审核再跑。